

Árbol de Decisión: Empresa de Telecomunicaciones

Facundo Lugo

Tecnicatura Superior en Ciencia de Datos e Inteligencia Artificial

Materia: Procesamiento de Aprendizaje Automático

Profesora: Yanina Scudero

23 de septiembre de 2026

Resumen

El presente trabajo práctico aborda la construcción e interpretación de un modelo de clasificación basado en árboles de decisión para predecir si un cliente de telecomunicaciones aceptará una oferta de plan de datos móviles. Se evalúa la entropía del conjunto original y la ganancia de información (*Information Gain*) para tres atributos clave: línea fija, uso mensual de datos y edad. El atributo con mayor ganancia de información es seleccionado como nodo raíz, logrando una clasificación óptima y reduciendo la entropía del modelo a cero en el primer nivel de división.

1. Conjunto de Datos Original

El dataset inicial cuenta con $N = 10$ registros de clientes. La variable objetivo a predecir es de carácter binario: **Aceptó Oferta** (*Sí/No*).

Tabla 1

Atributos y Registros del Conjunto de Datos Original

ID	Edad (años)	Uso de Datos (GB)	Tiene Línea Fija	Aceptó Oferta
1	24	2.5	No	No
2	38	6.0	Sí	Sí
3	29	3.0	No	No

4	45	8.0	Sí	Sí
5	52	7.5	Sí	Sí
6	33	4.0	No	No
7	41	5.5	Sí	Sí
8	27	2.0	No	No
9	36	6.5	Sí	Sí
10	31	3.5	No	No

Nota. Elaboración propia a partir de los datos recolectados.

2. Entropía del Conjunto Original

La entropía de Shannon (H) mide la impureza o incertidumbre del conjunto de datos. Para un sistema con dos clases de distribución uniforme, la entropía alcanza su valor máximo.

2.1. Cálculo Matemático

1. Conteo de clases:

- $N = 10$
- $Sí = 5$
- $No = 5$

2. Probabilidades de clase:

$$p(Sí) = \frac{5}{10} = 0.5$$

$$p(No) = \frac{5}{10} = 0.5$$

3. Ecuación de Entropía:

$$H(S) = - \sum_{i=1}^c p_i \log_2(p_i)$$

$$H(S) = - [p(\text{Sí}) \log_2(p(\text{Sí})) + p(\text{No}) \log_2(p(\text{No}))]$$

$$H(S) = - [0.5 \log_2(0.5) + 0.5 \log_2(0.5)]$$

$$H(S) = - [0.5 \cdot (-1) + 0.5 \cdot (-1)] = 1.0 \text{ bit}$$

2.2. Interpretación

El valor $H(S) = 1.0 \text{ bit}$ indica una incertidumbre máxima en el conjunto de datos inicial, ya que existe una división equitativa entre ambas clases (50% de aceptación y 50% de rechazo). Es imperativo segmentar el conjunto mediante los atributos disponibles para reducir la entropía.

3. Evaluación de la Ganancia de Información (IG)

La Ganancia de Información (IG) mide la reducción de la entropía esperada tras segmentar el conjunto original S por un atributo A :

$$IG(S, A) = H(S) - H_{\text{pond}}(S | A)$$

donde la Entropía Ponderada $H_{\text{pond}}(S | A)$ se expresa como:

$$H_{\text{pond}}(S | A) = \sum_{v \in \text{Valores}(A)} \frac{|S_v|}{|S|} H(S_v)$$

A) Atributo: Tiene Línea Fija

Paso 1: Subconjuntos

- **No:** IDs $\{1, 3, 6, 8, 10\} \rightarrow \text{Total} = 5$ (0 Sí / 5 No)
- **Sí:** IDs $\{2, 4, 5, 7, 9\} \rightarrow \text{Total} = 5$ (5 Sí / 0 No)

Paso 2: Entropías de Subconjuntos

$$H(S_{\text{No}}) = - \left[0 + \frac{5}{5} \log_2 \left(\frac{5}{5} \right) \right] = 0.0 \text{ bits}$$

$$H(S_{\text{Si}}) = - \left[\frac{5}{5} \log_2 \left(\frac{5}{5} \right) + 0 \right] = 0.0 \text{ bits}$$

Paso 3: Entropía Ponderada

$$H_{\text{pond}}(S \mid \text{LíneaFija}) = \frac{5}{10}(0.0) + \frac{5}{10}(0.0) = 0.0000 \text{ bits}$$

Paso 4: Ganancia de Información

$$IG(S, \text{LíneaFija}) = 1.0 - 0.0000 = 1.0000 \text{ bit}$$

B) Atributo: Uso de Datos

Paso 1: Subconjuntos

- Bajo ($\leq 3 \text{ GB}$): IDs $\{1, 3, 8\} \rightarrow \text{Total} = 3$ (0 Sí / 3 No)
- Medio ($3.1-6 \text{ GB}$): IDs $\{2, 6, 7, 10\} \rightarrow \text{Total} = 4$ (2 Sí / 2 No)
- Alto ($> 6 \text{ GB}$): IDs $\{4, 5, 9\} \rightarrow \text{Total} = 3$ (3 Sí / 0 No)

Paso 2: Entropías de Subconjuntos

$$H(S_{\text{Bajo}}) = 0.0 \text{ bits (Puro)}$$

$$H(S_{\text{Medio}}) = - \left[\frac{2}{4} \log_2 \left(\frac{2}{4} \right) + \frac{2}{4} \log_2 \left(\frac{2}{4} \right) \right] = 1.0 \text{ bit}$$

$$H(S_{\text{Alto}}) = 0.0 \text{ bits (Puro)}$$

Paso 3: Entropía Ponderada

$$H_{\text{pond}}(S \mid \text{Uso}) = \frac{3}{10}(0.0) + \frac{4}{10}(1.0) + \frac{3}{10}(0.0) = 0.4000 \text{ bits}$$

Paso 4: Ganancia de Información

$$IG(S, \text{Uso}) = 1.0 - 0.4000 = 0.6000 \text{ bit}$$

C) Atributo: Edad

Paso 1: Subconjuntos

- Joven (≤ 30): IDs $\{1, 3, 8\} \rightarrow \text{Total} = 3$ (0 Sí / 3 No)
- Adulto ($31-50$): IDs $\{2, 4, 6, 7, 9, 10\} \rightarrow \text{Total} = 6$ (4 Sí / 2 No)
- Mayor (> 50): IDs $\{5\} \rightarrow \text{Total} = 1$ (1 Sí / 0 No)

Paso 2: Entropías de Subconjuntos

$$H(S_{\text{Joven}}) = 0.0 \text{ bits}$$

$$H(S_{\text{Adulto}}) = - \left[\frac{4}{6} \log_2 \left(\frac{4}{6} \right) + \frac{2}{6} \log_2 \left(\frac{2}{6} \right) \right] \approx 0.9183 \text{ bits}$$

$$H(S_{\text{Mayor}}) = 0.0 \text{ bits}$$

Paso 3: Entropía Ponderada

$$H_{\text{pond}}(S \mid \text{Edad}) = \frac{3}{10}(0.0) + \frac{6}{10}(0.9183) + \frac{1}{10}(0.0) = 0.5510 \text{ bits}$$

Paso 4: Ganancia de Información

$$IG(S, \text{Edad}) = 1.0 - 0.5510 = 0.4490 \text{ bit}$$

4. Tabla Comparativa de Resultados

El criterio para seleccionar el nodo raíz exige escoger el atributo que maximice la Ganancia de Información (IG) o, de manera equivalente, minimice la Entropía Ponderada (H_{pond}).

Tabla 2

Comparación de Atributos según Entropía Ponderada y Ganancia de Información


Atributo	Entropía Ponderada (Hpond)	Ganancia de Información (IG)	Clasificación / Resultado
Tiene línea fija	0.0000	1.0000	Óptimo (Seleccionado)
Uso de datos	0.4000	0.6000	Secundario
Edad	0.5510	0.4490	Tercero

Nota. El atributo "Tiene línea fija" ofrece una separación perfecta sin necesidad de divisiones adicionales.

5. Construcción del Árbol de Decisión

5.1. Pasos de Construcción

- Selección de la Raíz:** Se establece el atributo **Tiene línea fija** por presentar la máxima Ganancia de Información ($IG = 1.0000$).
- Generación de Ramas:**
 - Rama "No":** Contiene los casos $\{1, 3, 6, 8, 10\}$. Todos corresponden a **Aceptó = NO**.
 - Rama "Sí":** Contiene los casos $\{2, 4, 5, 7, 9\}$. Todos corresponden a **Aceptó = Sí**.
- Criterio de Parada:** Ambas hojas presentan una entropía $H = 0.0 \text{ bits}$ (nodos puros), por lo que el algoritmo detiene su ejecución en el nivel 1.



6. Conclusión, Reglas de Predicción e Inferencia

El mejor atributo para iniciar el árbol es **Tiene línea fija**, ya que maximiza la ganancia de información ($IG = 1.0000$) al reducir la entropía de 1.0 bit a 0.0 bits en un solo nivel de división.

Los atributos Uso de datos (IG = 0.6000) y Edad (IG = 0.4490) dejan subconjuntos mixtos, por lo que requerirían divisiones adicionales. Para predecir si un nuevo cliente aceptará la oferta, basta con consultar si tiene línea fija: si la tiene, se predice que acepta; si no, se predice que rechaza.

1. **Regla 1:** SI Tiene línea fija = "No" $\implies$ Aceptó Oferta = "No"
2. **Regla 2:** SI Tiene línea fija = "Sí" $\implies$ Aceptó Oferta = "Sí"

Ejemplos de Inferencia

- **Ejemplo A:** Un nuevo cliente de 40 años, con uso de 5 GB y línea fija contratada.
 - *Evaluación:* ¿Tiene línea fija? $\rightarrow$ Sí.
 - *Predicción:* **Acepta la oferta.**
- **Ejemplo B:** Un nuevo cliente de 25 años, con uso de 2 GB y sin línea fija.
 - *Evaluación:* ¿Tiene línea fija? $\rightarrow$ No.
 - *Predicción:* **No acepta la oferta.**